Create Autoscaling VM's – on GCP

Use case :
Seorang system admin ingin aplikasinya selalu available dan juga bisa ter-scale saat tingkat request pada server bertambah, dalam arti akan dibuatkan sebuah cluster VM's yang mampu memberikan layanan dimana saat banyak yang mengakses server/aplikasi maka otomatis jumlah server(VM) yang menjalankan aplikasi tersebut bisa bertambah dengan sendirinya, serta jika jumlah request berkurang maka server(VM) akan berkurang juga. Cluster ini akan dihubungkan dengan sebuah load balancer yang berfungsi sebagai forwading serta menyediakan expose IP untuk digunakan untuk domain.

Prerequisite:
Memiliki google container Registry, yang berfungsi sebagai private registry

Flow:

Step by Step:

- Buka https://console.cloud.google.com/

- Sekarang kita akan membuat Custom Image yang telah terinstall Docker + Google SDK, yang berfungsi sebagai default image sehingga tidak diperlukan lagi start script untuk mengistall Docker dan Google SDK. Hal ini juga bertujuan untuk mempercepat time to UP aplikasi nantinya.

- Klik Compute Engine → VM Instances → Create Instance → buat sesuai dengan requirement Server anda → SSH dan install Docker services + Google SDK → setelah terinstall klik vm dan Edit → pada Boot Disk , centang Deletion rule, hal ini untuk mencegah image dari VM terhapus saat VM di destroy → Delete VM

- Klik Compute Engine → Images → Create an image → isi nama dan pada bagian Source pilih Disk → Source Disk, cari nama VM yang telah diDelete tadi → Pilih Location sesuai kebutuhan anda → Family, Desc, Label adalah opsional sesuai kebutuhan → Create

- Sekarang kita akan membuat instance templates, hal ini bertujuan agar instance group nantinya memiliki instance template yang sama.

- Klik Compute Engine → Instance templates → Create Instance template → isi nama, tipe machine → pada bagian Boot disk change pilih custom images dan pilih images yang telah dicustom tadi → tambahkan firewall rules, serta jika ada tambahan di Management, security, disks, networking, sole tenancy → Create

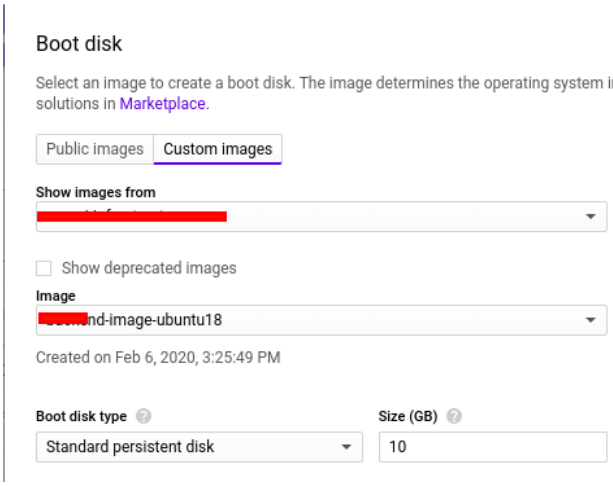

- Setelah kita memiliki instance template, sekarang kita akan membuat instance group.

- Klik Compute engine → Instance groups → Create an instance group → isi nama, deskripsi, location → pada bagian Instance template, pilih instance template yang telah dibuat sebelumnnya → Autoscaling mode pilih Autoscale → Autoscaling metrics pilih default (CPU utilization: 60%) untuk mengetahui lebih lanjut mengenai policy autoscaling dapat dibaca di https://cloud.google.com/compute/docs/autoscaler → cool down period = 60 s → kemudian isi number minimum instances 1 dan max 3 (sesuai kebutuhan anda), bagian ini bertujuan untuk membatasi jumlah VM maksimal yang dapat di create saat trafik telah mencukupi berdasarkan metrik → Autohealing, create dengan protocol HTTP:80 → Create

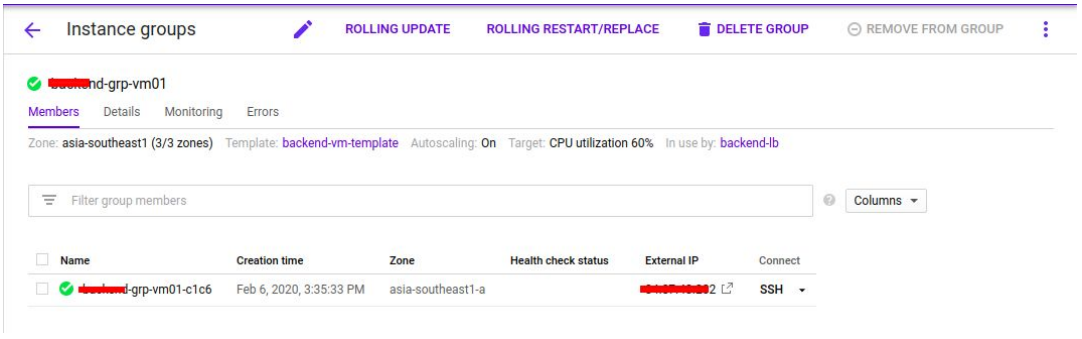

- Setelah instance group telah selesai di setup, kita butuh loadbalancer sebagai wadah untuk menghubungkan user kepada vm-vm yang ada di instance group.

- Klik network services → Load balancing → create load balancer → HTTP(S) Load Balancing → Start Configuration → From internet to my Vms → Isi nama → Backend Configuration, Backend Services, create a backend services → isi nama → new backend, pilih instance group yang telah disetup sebelumnnya → setup balancing mode, done → pilih/create Health check → Create

Host and Path rules, pada bagian ini anda dapat mengarahkan traffic berdasarkan host dan backend yang tersedia.

Pada bagian Frontend Configuration, isi nama → protocol HTTP → IP Version, create IP address → Done

Review and finalize → Create

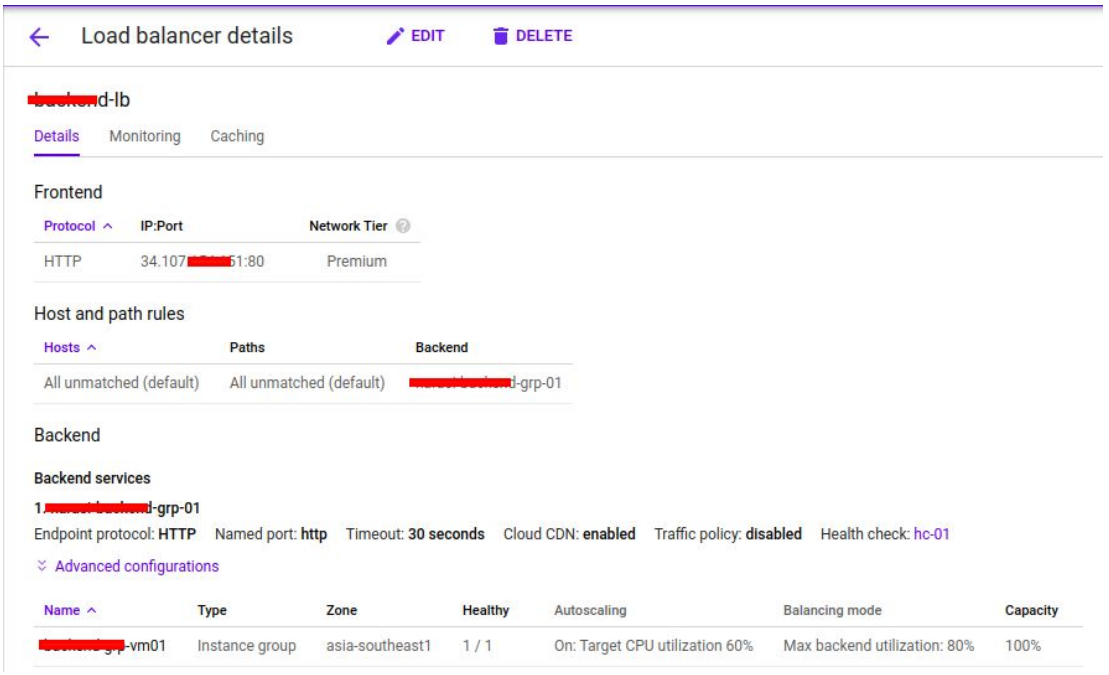

Test, untuk bagian ini saya menggunakan loader test untuk melakukan hit ke server untuk melihat autoscaling pada instance group.